

## 7. Componente Empírico del Proyecto

Protocolo Ejecutado y Resultados – Enfoque 2: Detección Automática de Ambigüedad

*MundiPets – Ingeniería de Requerimientos [20303] – UTEQ 2026–2027 PPA*

*Entrega 4 (2B / Defensa Final)*

### Nota de versión

Este documento actualiza el protocolo registrado en el Open Science Framework (OSF) el 27 de julio de 2026 (Sección 7.8) con lo efectivamente ejecutado durante la Entrega 4 (2B). Toda diferencia respecto del protocolo original se documenta explícitamente con su justificación, en cumplimiento de la exigencia de la guía de que ninguna desviación quede sin registrar; estas se consolidan además en la Sección 7.8.

### 7.1 Enfoque seleccionado y justificación

El equipo optó por el **Enfoque 2 – Detectar automáticamente ambigüedad y malos olores en los requisitos**, descartando el Enfoque 1 (comparación de la calidad de los RF frente a un LLM) y el Enfoque 3 (validación de requisitos de explicabilidad del componente de IA).

**Justificación en función del sistema.** MundiPets contaba, desde la Entrega 2 (1B), con un corpus consolidado de especificación que constituyó el insumo directo sobre el cual se ejecutó el detector de ambigüedad, sin depender de instrumentos adicionales de recolección con usuarios externos al proyecto.

**Justificación en función de los datos disponibles.** Como parte de la revisión y refinamiento del ERS/SRS, el equipo ya había efectuado un primer ejercicio de identificación manual de defectos de redacción, detectando patrones de ambigüedad, terminología imprecisa y requisitos no verificables consistentes con los malos olores descritos por Ferrari et al. [1]. Este antecedente ofreció una base real sobre la cual diseñar y calibrar el detector automático.

**Justificación en función del tiempo.** Los Enfoques 1 y 3 dependen de reclutar y coordinar agendas con personas ajenas al equipo, lo cual introduce una latencia que no se reduce aunque se disponga de más semanas. El Enfoque 2, en cambio, mantuvo su ruta crítica dentro del equipo: solo requirió tres personas expertas ya identificadas y la construcción de un detector automático, ambas tareas ejecutables sin depender de la disponibilidad de terceros.

La decisión fue adoptada internamente por el equipo.

### 7.2 Preguntas de investigación en formato PICOC

| Elemento PI-COC | Descripción                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Población       | Conjunto de requisitos funcionales (RF), no funcionales (RNF), restricciones de diseño (RD) y obligaciones legales (RL) especificados para el sistema MundiPets, redactados según la plantilla de atributos exigida por la asignatura y vigentes al momento de la ejecución del experimento. La población final ejecutada es de <b>61 requisitos</b> (27 RF, 16 RNF, 9 RD, 9 RL), frente a los 30 previstos en el registro previo del protocolo (17 RF, 8 RNF, 5 RD). El corpus se amplió al incorporar los requisitos consolidados en la versión final del ERS/SRS (Sección 01_ERS), incluida la categoría RL (obligaciones legales), no contemplada en el registro original. La ampliación fue posible porque la especificación completa del sistema quedó disponible antes del cierre de la recolección, y se aplicó de forma completa — no selectiva — sobre el corpus final, evitando cualquier sesgo de selección posterior a la observación de resultados. |
| Intervención    | Clasificación automática de cada requisito como ambiguo o no ambiguo mediante un detector basado en reglas, que identifica cuantificadores vagos, conjunciones múltiples que ocultan más de un requisito, voz pasiva y ausencia de criterio de verificación explícito.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| Comparación     | Clasificación manual e independiente del mismo conjunto de requisitos, realizada por tres personas expertas en Ingeniería de Requisitos, sin conocimiento previo de la salida del detector (evaluación a ciegas).                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
| Resultado       | Precisión, exhaustividad (recall) y medida F1 del detector automático tomando como referencia el consenso experto; acuerdo inter-evaluador mediante $\kappa$ de Cohen entre pares de expertos y $\kappa$ de Fleiss para el conjunto de los tres; significancia de la asociación detector–consenso.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
| Contexto        | Proyecto académico de la asignatura de Ingeniería de Requerimientos [20303] (UTEQ, 2026–2027 PPA), aplicado al sistema real MundiPets, con especificación redactada en español.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |

**RQ1** ¿Con qué precisión, exhaustividad y medida F1 replica un detector automático basado en reglas el juicio consensuado de personas expertas al clasificar como ambiguos los requisitos especificados para MundiPets?

**RQ2** ¿Qué patrones de desacuerdo predominan entre el detector automático y el juicio experto, y qué explican sobre las limitaciones de un enfoque basado en reglas frente al juicio humano en la identificación de ambigüedad?

### 7.3 Hipótesis del estudio

**H0 (hipótesis nula):** la clasificación producida por el detector automático de ambigüedad no guarda asociación con la clasificación de consenso de las personas expertas.

**H1 (hipótesis alternativa):** la clasificación producida por el detector automático de ambigüedad guarda asociación significativa con la clasificación de consenso de las personas expertas.

El contraste de H0/H1 se ejecutó mediante una **prueba de chi-cuadrado de independencia de Pearson** (con corrección de continuidad) sobre la tabla de contingencia 2×2 detector–consenso, en lugar de la prueba de significancia del  $\kappa$  de Cohen ( $z = \kappa/SE_{\kappa}$ ) prevista originalmente en el registro OSF. El cambio se debe a que el chi-cuadrado de independencia es la prueba

estándar para contrastar asociación entre dos variables categóricas binarias medidas sobre las mismas unidades (el diseño exacto de este estudio), y permite reportar directamente el tamaño del efecto como coeficiente  $\phi$  (phi), interpretable en la misma escala que una correlación. Los resultados de acuerdo inter-evaluador ( $\kappa$  de Cohen y de Fleiss, Sección 7.7) se mantuvieron sin cambios respecto al plan original.

## 7.4 Variables independientes, dependientes y de control

**Variable independiente.** El método de clasificación aplicado a cada requisito, con dos niveles: (a) detector automático basado en reglas y (b) consenso de las tres personas expertas.

**Variable dependiente.** La clasificación resultante de cada requisito como ambiguo o no ambiguo (variable categórica binaria), a partir de la cual se calculan las métricas de acuerdo declaradas en la Sección 7.7.

**Variables de control.**

- Tipo de requisito (RF, RNF, RD o RL), para verificar que el desempeño del detector no varíe sistemáticamente según el tipo de artefacto evaluado.
- Configuración fija del detector: el conjunto de reglas permaneció invariable durante toda la ejecución del experimento; ninguna regla se ajustó después de observar resultados parciales.
- Orden de presentación de los requisitos a las personas expertas, aleatorizado de forma independiente para cada evaluador.
- Cegamiento del juicio experto: ninguna persona evaluadora tuvo acceso a la salida del detector ni a la clasificación de las demás personas evaluadoras antes de completar la propia.

## 7.5 Participantes

El panel estuvo compuesto por tres Ingenieros de Software graduados de la Universidad Técnica Estatal de Quevedo (UTEQ), identificados en el material publicado únicamente por código (**EXP-01**, **EXP-02**, **EXP-03**) para proteger su identidad; la correspondencia entre código e identidad real se conserva exclusivamente en un anexo de uso interno del equipo, fuera de la zona pública del repositorio.

Cada persona evaluadora firmó, el 28 de julio de 2026, un consentimiento informado específico para este rol, redactado en cumplimiento de la Ley Orgánica de Protección de Datos Personales del Ecuador [2], que autoriza expresamente su participación como evaluadora experta y el uso de la clasificación producida –de forma anonimizada– en publicaciones científicas revisadas por pares.

## 7.6 Instrumentos

1. **Rúbrica de clasificación experta** (`rubrica_clasificacion_experta.xlsx`): libro con hoja de instrucciones, hoja de criterios de referencia para identificar ambigüedad, y una hoja de evaluación por persona (**Eval.** EXP-01/02/03) en la que cada evaluadora registró, para cada requisito, su identificador anónimo, el texto completo, la clasificación (ambiguo / no ambiguo), el tipo de mal olor detectado, una justificación breve y su nivel de confianza (escala 1–5). Una hoja adicional (**Clave Interna**), de uso exclusivo del equipo, conserva la clave que vincula cada identificador anónimo con el requisito real y la salida del detector.

2. **Plantilla de consentimiento para evaluadores expertos:** adapta el formato de consentimiento ya utilizado en entregas anteriores para entrevistas, ajustado al rol de evaluador experto.

## 7.7 Plan de análisis estadístico ejecutado

**Análisis principal (RQ1, H0/H1).** Se calcularon precisión, exhaustividad y medida F1 del detector automático tomando como referencia el consenso experto. La hipótesis se contrastó mediante chi-cuadrado de independencia de Pearson (véase la desviación documentada en la Sección 7.3), y la magnitud del acuerdo se interpretó con la escala de Landis y Koch [3]: 0,00–0,20 leve; 0,21–0,40 aceptable; 0,41–0,60 moderado; 0,61–0,80 sustancial; 0,81–1,00 casi perfecto.

**Acuerdo inter-evaluador.**  $\kappa$  de Cohen [4] para cada par de las tres personas expertas, y  $\kappa$  de Fleiss [5] para el conjunto de las tres, interpretados con la misma escala de Landis y Koch.

El análisis secundario exploratorio de RQ2 (comparación del nivel de confianza entre casos de acuerdo y desacuerdo mediante prueba de Shapiro-Wilk seguida de t de Student o U de Mann-Whitney, con corrección de Benjamini-Hochberg para comparaciones por tipo de requisito) **no se ejecutó** dentro del plazo de la Entrega 4 (2B). RQ2 se respondió de forma cualitativa mediante el análisis de los tipos de mal olor predominantes en los casos de desacuerdo (Sección 7.10), tal como permite el sexto paso del Enfoque 2 en la guía de la asignatura. El análisis cuantitativo de RQ2 queda declarado como trabajo futuro (Sección 7.12).

**Cálculo de potencia estadística.** Conforme a Molléri et al. [6] y Wohlin et al. [7], se fijó  $\alpha = 0,05$  y  $1 - \beta = 0,80$ . El cálculo de potencia se reportó en sentido inverso sobre el N real disponible (61), mediante remuestreo bootstrap (10 000 réplicas, semilla fija = 42) para el intervalo de confianza al 95 % de cada métrica.

**Reproducibilidad.** Todos los cálculos se ejecutan mediante los scripts versionados en 06\_Experimento/scripts\_analisis/ (Python: pandas, scipy, numpy), orquestados por un único punto de entrada (run\_all.py). Ninguna cifra o tabla de esta sección se produjo de forma manual; se verificó la reproducibilidad completa ejecutando el pipeline sobre un clon limpio del repositorio, partiendo únicamente de datos\_crudos/.

## 7.8 Registro previo y desviaciones respecto del protocolo

El protocolo del Enfoque 2 se registró en el Open Science Framework [8], mediante la plantilla OSF Preregistration, el 27 de julio de 2026 a las 10:49:41 a.m. (hora de Ecuador), antes de distribuir la rúbrica de clasificación al panel experto y antes de ejecutar el detector automático sobre el corpus de requisitos. El registro puede consultarse en: <https://osf.io/khyf2/overview>.

Esta sección consolida, en un solo lugar, las tres desviaciones documentadas respecto del protocolo pre-registrado:

1. **Tamaño y composición de la población:** de 30 requisitos previstos (17 RF, 8 RNF, 5 RD) a 61 ejecutados (27 RF, 16 RNF, 9 RD, 9 RL), con la incorporación de la categoría RL no contemplada originalmente (Sección 7.2).
2. **Prueba de significancia estadística:** de la prueba de  $z$  sobre el  $\kappa$  de Cohen a chi-cuadrado de independencia de Pearson con corrección de continuidad (Sección 7.3).
3. **Análisis secundario de RQ2:** el componente cuantitativo (Shapiro-Wilk, prueba de comparación de grupos, corrección Benjamini-Hochberg) no se ejecutó; RQ2 se respondió mediante análisis cualitativo de los tipos de mal olor (Sección 7.10).

Ninguna de las tres desviaciones alteró la variable dependiente, el diseño ciego, ni el conjunto de reglas fijas del detector; todas se aplicaron de forma completa sobre el corpus final, no de manera selectiva sobre resultados ya observados.

## 7.9 Amenazas a la validez

### Validez interna

**Sesgo de diseño del detector.** El equipo que construyó el detector ya conocía, por la revisión manual previa realizada durante el refinamiento del ERS/SRS, algunos de los defectos presentes en una parte del corpus, lo que podría calibrar las reglas hacia esos casos conocidos. *Mitigación:* las reglas del detector se fijaron y documentaron antes de recibir la clasificación completa de los tres expertos, y se aplicaron sin modificación posterior. *Limitación reconocida:* el sesgo no se elimina por completo.

**Efecto de orden o fatiga en la evaluación experta.** *Mitigación:* orden de presentación aleatorizado de forma independiente para cada evaluador. *Limitación reconocida:* la aleatorización distribuye el efecto pero no lo elimina.

### Validez externa

**Corpus de un solo sistema y dominio.** Los requisitos provienen únicamente de MundiPets, en español, dominio veterinario/adopción de mascotas. *Mitigación:* el contexto queda documentado explícitamente en el marco PICOC. *Limitación reconocida:* no puede afirmarse que el desempeño del detector generalice a otros dominios, idiomas o equipos.

**Homogeneidad del panel experto.** Las tres personas evaluadoras son ingenieras e ingeniero de software graduados de la misma universidad. *Mitigación:* el perfil del panel se documenta explícitamente. *Limitación reconocida:* no se garantiza representatividad de la diversidad de juicio experto de un panel más amplio o multi-institucional.

### Validez de constructo

**Binarización de un fenómeno gradual.** *Mitigación:* la rúbrica captura matices adicionales mediante el tipo de mal olor y el nivel de confianza. *Limitación reconocida:* la variable principal de análisis sigue siendo binaria.

**Alcance limitado de un detector basado en reglas.** El detector identifica ambigüedad léxica y sintáctica, no ambigüedad semántica de dominio. *Mitigación:* el alcance de las reglas se documenta explícitamente. *Limitación reconocida:* la comparación mide específicamente cuánta ambigüedad detectable por reglas léxicas coincide con el juicio experto global.

### Validez de conclusión

**Tamaño de muestra.** A diferencia de lo previsto en el registro original –que señalaba un N por debajo del mínimo sugerido–, el corpus final ejecutado (N=61) supera el mínimo de 50 requisitos sugerido por la guía de la asignatura para este enfoque, lo que mejoró sustancialmente la potencia estadística respecto de lo previsto. *Resultado observado:* con este N, la asociación detector–consenso resultó estadísticamente significativa ( $p = 0,0001$ ), a diferencia de lo que habría ocurrido con el N menor previsto originalmente.

**Panel experto mínimo.** Solo tres personas conforman el consenso de referencia, el mínimo aceptado por la guía. *Mitigación:* se calculó explícitamente el acuerdo inter-evaluador mediante  $\kappa$  de Fleiss antes de aceptar el consenso como válido (Sección 7.7). *Limitación reconocida:* un panel de tres es más vulnerable a la idiosincrasia individual que un panel de cinco.

## 7.10 Resultados obtenidos

### 7.10.1 Clasificación por fuente

Cuadro 2: Clasificación de ambigüedad por fuente (N=61).

| Fuente              | N  | Ambiguos (n) | Ambiguos (%) |
|---------------------|----|--------------|--------------|
| EXP-01              | 61 | 16           | 26,23        |
| EXP-02              | 61 | 13           | 21,31        |
| EXP-03              | 61 | 18           | 29,51        |
| Consenso experto    | 61 | 16           | 26,23        |
| Detector automático | 61 | 20           | 32,79        |

### 7.10.2 Acuerdo inter-evaluador

Cuadro 3: Acuerdo inter-evaluador ( $\kappa$  de Cohen por par,  $\kappa$  de Fleiss para el panel).

| Comparación                                           | $\kappa$      | Acuerdo obs.  | Interpretación       |
|-------------------------------------------------------|---------------|---------------|----------------------|
| EXP-01 vs. EXP-02                                     | 0,8647        | 0,9508        | Casi perfecto        |
| EXP-01 vs. EXP-03                                     | 0,9186        | 0,9672        | Casi perfecto        |
| EXP-02 vs. EXP-03                                     | 0,7857        | 0,9180        | Sustancial           |
| <b>Panel completo (<math>\kappa</math> de Fleiss)</b> | <b>0,8569</b> | <b>0,9454</b> | <b>Casi perfecto</b> |

El acuerdo casi perfecto obtenido en el panel completo respalda la validez del consenso experto como referencia para evaluar el detector automático.

### 7.10.3 Desempeño del detector y prueba de hipótesis

Cuadro 4: Matriz de confusión: detector vs. consenso experto (N=61).

| Consenso experto | Detector: No ambiguo | Detector: Ambiguo |
|------------------|----------------------|-------------------|
| No ambiguo       | 37                   | 8                 |
| Ambiguo          | 4                    | 12                |

Cuadro 5: Métricas del detector automático con intervalo de confianza al 95 % (bootstrap, 10 000 réplicas).

| Métrica                    | Valor             | IC 95 %          |
|----------------------------|-------------------|------------------|
| Exactitud                  | 0,8033            | [0,7049; 0,9016] |
| Precisión                  | 0,6000            | [0,3750; 0,8125] |
| Sensibilidad               | 0,7500            | [0,5000; 0,9412] |
| Especificidad              | 0,8222            | [0,7027; 0,9269] |
| Medida F1                  | 0,6667            | [0,4571; 0,8205] |
| $\kappa$ detector–consenso | 0,5296 (moderado) | [0,2797; 0,7369] |

**Prueba de hipótesis:**  $\chi^2(1) = 15,0374$ ;  $p = 0,0001$ ;  $\phi = 0,4965$  (tamaño del efecto moderado–grande).

Con  $p < 0,05$ , se **rechaza H0**: la clasificación del detector automático guarda asociación estadísticamente significativa con el consenso experto, con un tamaño del efecto moderado–grande.

#### 7.10.4 Tipos de ambigüedad predominantes (RQ2)

Cuadro 6: Distribución de tipos de mal olor sobre las marcaciones ambiguas.

| Tipo de ambigüedad                    | Frecuencia | %     |
|---------------------------------------|------------|-------|
| Terminología imprecisa                | 18         | 38,30 |
| Cuantificador vago                    | 15         | 31,91 |
| Requisito no verificable / incompleto | 9          | 19,15 |
| Conjunción múltiple                   | 5          | 10,64 |

El tipo de ambigüedad predominante en los casos marcados por el panel experto es la terminología imprecisa, seguida de cerca por los cuantificadores vagos –el tipo de mal olor que el detector basado en reglas está diseñado para capturar de forma más directa–, lo que es consistente con la sensibilidad de 0,75 obtenida.

### 7.11 Síntesis de respuesta a las preguntas de investigación

**RQ1.** El detector automático basado en reglas replica el juicio consensuado de las personas expertas con una exactitud de 0,8033, una medida F1 de 0,6667 y un acuerdo moderado ( $\kappa = 0,5296$ ) con el consenso experto, una asociación estadísticamente significativa ( $\chi^2(1) = 15,0374$ ;  $p = 0,0001$ ;  $\phi = 0,4965$ ).

**RQ2.** Los desacuerdos entre el detector y el consenso experto se concentran en requisitos donde predomina la terminología imprecisa y la ausencia de criterio de verificación explícito –formas de ambigüedad semántica que requieren juicio de dominio– frente a los cuantificadores vagos, que el detector identifica de forma más directa mediante reglas léxicas.

### 7.12 Trabajo futuro declarado

Como se documenta en la Sección 7.7, el análisis cuantitativo secundario de RQ2 (comparación del nivel de confianza entre casos de acuerdo y desacuerdo, con las pruebas y correcciones originalmente previstas) queda pendiente de ejecución y se declara explícitamente como línea de trabajo futuro sobre el mismo conjunto de datos ya depositado.

*Todos los valores numéricos de esta sección provienen directamente de 06\_Experimento/resultados/tablas/ (tablas 1 a 9), generadas por los scripts versionados en 06\_Experimento/scripts\_analisis/ a partir de datos\_crudos/. Ningún valor fue calculado, redondeado o transcrito manualmente para este documento.*

## Referencias

- [1] Ferrari, A., Gnesi, S., & Tolomei, G. (2014). A Case Study on the Impact of Software Requirements Quality on Related Work Products. *Requirements Engineering*, 19(2), 209–234.
- [2] Asamblea Nacional del Ecuador. (2021). *Ley Orgánica de Protección de Datos Personales*. Registro Oficial Suplemento No. 459, 26 de mayo de 2021.

- [3] Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, 33(1), 159–174.
- [4] Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- [5] Fleiss, J. L. (1971). Measuring Nominal Scale Agreement Among Many Raters. *Psychological Bulletin*, 76(5), 378–382.
- [6] Molléri, J. S., Petersen, K., & Mendes, E. (2020). An Empirically Evaluated Checklist for Surveys in Software Engineering. *Information and Software Technology*, 119, 106240.
- [7] Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., & Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.
- [8] Center for Open Science. *Open Science Framework (OSF)*. <https://osf.io>.