

7. Componente Empírico del Proyecto

Protocolo Ejecutado y Resultados – Enfoque 2: Detección Automática de Ambigüedad

MundiPets – Ingeniería de Requerimientos [20303] – UTEQ 2026-2027 PPA

Entrega 4 (2B / Defensa Final)

7.1 Enfoque seleccionado y justificación

El equipo optó por el **Enfoque 2 – Detectar automáticamente ambigüedad y malos olores en los requisitos**, descartando el Enfoque 1 (comparación de la calidad de los RF frente a un LLM) y el Enfoque 3 (validación de requisitos de explicabilidad del componente de IA).

Justificación en función del sistema. MundiPets contaba, desde la Entrega 2 (1B), con un corpus consolidado de especificación que constituyó el insumo directo sobre el cual se ejecutó el detector de ambigüedad, sin depender de instrumentos adicionales de recolección con usuarios externos al proyecto.

Justificación en función de los datos disponibles. Como parte de la revisión y refinamiento del ERS/SRS, el equipo ya había efectuado un primer ejercicio de identificación manual de defectos de redacción, detectando patrones de ambigüedad, terminología imprecisa y requisitos no verificables consistentes con los malos olores descritos por Ferrari et al. [1]. Este antecedente ofreció una base real sobre la cual diseñar y calibrar el detector automático.

Justificación en función del tiempo. Los Enfoques 1 y 3 dependen de reclutar y coordinar agendas con personas ajenas al equipo, lo cual introduce una latencia que no se reduce aunque se disponga de más semanas. El Enfoque 2, en cambio, mantuvo su ruta crítica dentro del equipo: solo requirió tres personas expertas ya identificadas y la construcción de un detector automático, ambas tareas ejecutables sin depender de la disponibilidad de terceros.

La decisión fue adoptada internamente por el equipo.

7.2 Preguntas de investigación en formato PICOC

Elemento PI-COC	Descripción
Población	Conjunto de requisitos funcionales (RF), no funcionales (RNF), restricciones de diseño (RD) y obligaciones legales (RL) especificados para el sistema MundiPets, redactados según la plantilla de atributos exigida por la asignatura y vigentes al momento de la ejecución del experimento. La población final ejecutada es de 61 requisitos (27 RF, 16 RNF, 9 RD, 9 RL), frente a los 30 previstos en el registro previo del protocolo (17 RF, 8 RNF, 5 RD). El corpus se amplió al incorporar los requisitos consolidados en la versión final del ERS/SRS (Sección 01_ERS), incluida la categoría RL (obligaciones legales), no contemplada en el registro original. La ampliación fue posible porque la especificación completa del sistema quedó disponible antes del cierre de la recolección, y se aplicó de forma completa no selectiva sobre el corpus final, evitando cualquier sesgo de selección posterior a la observación de resultados.

Elemento COC	PI-	Descripción
Intervención		Clasificación automática de cada requisito como ambiguo o no ambiguo mediante un detector basado en reglas, que identifica cuantificadores vagos, conjunciones múltiples que ocultan más de un requisito, voz pasiva y ausencia de criterio de verificación explícito.
Comparación		Clasificación manual e independiente del mismo conjunto de requisitos, realizada por tres personas expertas en Ingeniería de Requisitos, sin conocimiento previo de la salida del detector (evaluación a ciegas).
Resultado		Precisión, exhaustividad (recall) y medida F1 del detector automático tomando como referencia el consenso experto; acuerdo inter-evaluador mediante κ de Cohen entre pares de expertos y κ de Fleiss para el conjunto de los tres; significancia de la asociación detector–consenso.
Contexto		Proyecto académico de la asignatura de Ingeniería de Requerimientos [20303] (UTEQ, 2026–2027 PPA), aplicado al sistema real MundiPets, con especificación redactada en español.

RQ1 ¿Con qué precisión, exhaustividad y medida F1 replica un detector automático basado en reglas el juicio consensuado de personas expertas al clasificar como ambiguos los requisitos especificados para MundiPets?

RQ2 ¿Qué patrones de desacuerdo predominan entre el detector automático y el juicio experto, y qué explican sobre las limitaciones de un enfoque basado en reglas frente al juicio humano en la identificación de ambigüedad?

7.3 Hipótesis del estudio

H0 (hipótesis nula): la clasificación producida por el detector automático de ambigüedad no guarda asociación con la clasificación de consenso de las personas expertas.

H1 (hipótesis alternativa): la clasificación producida por el detector automático de ambigüedad guarda asociación significativa con la clasificación de consenso de las personas expertas.

El contraste de H0/H1 se ejecutó mediante una prueba de chi-cuadrado de independencia de Pearson (con corrección de continuidad) sobre la tabla de contingencia 2×2 detector–consenso, en lugar de la prueba de significancia del κ de Cohen ($z = \kappa/SE_{\kappa}$) prevista originalmente en el registro OSF. El cambio se debe a que el chi-cuadrado de independencia es la prueba estándar para contrastar asociación entre dos variables categóricas binarias medidas sobre las mismas unidades (el diseño exacto de este estudio), y permite reportar directamente el tamaño del efecto como coeficiente ϕ (phi), interpretable en la misma escala que una correlación. Los resultados de acuerdo inter-evaluador (κ de Cohen y de Fleiss, Sección 7.7) se mantuvieron sin cambios respecto al plan original.

7.4 Variables independientes, dependientes y de control

Variable independiente. El método de clasificación aplicado a cada requisito, con dos niveles: (a) detector automático basado en reglas y (b) consenso de las tres personas expertas.

Variable dependiente. La clasificación resultante de cada requisito como ambiguo o no ambiguo (variable categórica binaria), a partir de la cual se calculan las métricas de acuerdo declaradas en la Sección 7.7.

Variables de control.

- Tipo de requisito (RF, RNF, RD o RL), para verificar que el desempeño del detector no varíe sistemáticamente según el tipo de artefacto evaluado.
- Configuración fija del detector: el conjunto de reglas permaneció invariable durante toda la ejecución del experimento; ninguna regla se ajustó después de observar resultados parciales.
- Orden de presentación de los requisitos a las personas expertas, aleatorizado de forma independiente para cada evaluador.
- Cegamiento del juicio experto: ninguna persona evaluadora tuvo acceso a la salida del detector ni a la clasificación de las demás personas evaluadoras antes de completar la propia.

7.5 Participantes

El panel estuvo compuesto por tres Ingenieros de Software graduados de la Universidad Técnica Estatal de Quevedo (UTEQ), identificados en el material publicado únicamente por código (**EXP-01**, **EXP-02**, **EXP-03**) para proteger su identidad; la correspondencia entre código e identidad real se conserva exclusivamente en un anexo de uso interno del equipo, fuera de la zona pública del repositorio.

Cada persona evaluadora firmó, el 28 de julio de 2026, un consentimiento informado específico para este rol, redactado en cumplimiento de la Ley Orgánica de Protección de Datos Personales del Ecuador [2], que autoriza expresamente su participación como evaluadora experta y el uso de la clasificación producida de forma anonimizada en publicaciones científicas revisadas por pares.

7.6 Instrumentos

1. **Rúbrica de clasificación experta** (`rubrica_clasificacion_experta.xlsx`): libro con hoja de instrucciones, hoja de criterios de referencia para identificar ambigüedad, y una hoja de evaluación por persona (**Eval.** EXP-01/02/03) en la que cada evaluadora registró, para cada requisito, su identificador anónimo, el texto completo, la clasificación (ambiguo / no ambiguo), el tipo de mal olor detectado, una justificación breve y su nivel de confianza (escala 1–5). Una hoja adicional (**Clave Interna**), de uso exclusivo del equipo, conserva la clave que vincula cada identificador anónimo con el requisito real y la salida del detector.
2. **Plantilla de consentimiento para evaluadores expertos**: adapta el formato de consentimiento ya utilizado en entregas anteriores para entrevistas, ajustado al rol de evaluador experto.

7.6.1 Protocolo de anotación, entrenamiento del panel y calibración

Esta subsección documenta cómo se operacionalizaron, ante el panel, los criterios de clasificación de la rúbrica descrita arriba, y deja constancia explícita de qué se hizo y qué no se hizo antes de la recolección de los 61 juicios reales.

Fuente

Las definiciones y ejemplos que siguen no son una reconstrucción posterior: corresponden textualmente a lo explicado al panel durante la sesión registrada en `2026-07-28_Reunion_Panel_Expertos_EXP-01-02-03_Transcripcion.md` (videollamada, 36 min 22 s), con cita de la marca de tiempo exacta de cada definición.

Las cinco categorías, con definición operativa y ejemplo

Categoría	Definición operativa	Ejemplo dado en la sesión
Cuantificador va- go (03:07)	Uso de términos subjetivos sin una métrica definida.	“necesito que mi sistema sea rápido, fácil de usar”; “consultar el perfil completo de una mascota” (no define qué información ni para qué usuario).
Conjunción múlti- ple (03:38)	Conjunciones que ocultan más de un requisito en una sola oración, dificultando su verificación individual.	“sistema de mensajería entre usuarios” (no indica bajo qué condición se habilita; mezcla registro y autorización).
Voz pasiva o sujeto ausente (04:05)	No queda claro quién ejecuta la acción o bajo qué rol, dificultando la trazabilidad hacia un actor.	“se debe validar la información médica” (no indica si lo hace el sistema, la veterinaria o el propietario).
Terminología im- precisa (04:29)	Palabras que admiten más de una interpretación técnica razonable dentro del dominio del sistema.	“validar la información médica de una mascota” (¿diagnóstico clínico, certificación oficial, o revisión documental?).
Requisito no veri- ficable o incomple- to (04:50)	No define un criterio, estado o umbral que permita comprobar objetivamente su cumplimiento.	“evaluar compatibilidad entre mascotas para cruce” (sin criterios mínimos de evaluación).

Nota sobre la categoría de voz pasiva o sujeto ausente: en el corpus final de 61 requisitos, ningún caso fue clasificado bajo esta categoría por ninguno de los tres evaluadores. La categoría se explicó igualmente al panel; su ausencia en los resultados refleja el corpus real ya redactado con actor explícito conforme a la plantilla de ocho atributos exigida por la asignatura y no un vacío del protocolo.

Ejemplos límite reales

A diferencia de los ejemplos de la tabla anterior (dados *antes* de conocer el corpus real, durante el entrenamiento), los siguientes cuatro casos son reales y corresponden a los únicos requisitos del corpus de 61 donde el panel no llegó a acuerdo unánime (2 de 3). Delimitan, con evidencia real, el punto exacto donde cada categoría se vuelve discutible incluso entre expertos.

Caso	Votación	Dónde está el límite
REQ-02	2/3 no ambiguo	La mayoría consideró que “entrega correcta, sin duplicación ni pérdida” ya es verificable mediante pruebas de envío; la minoría (EXP-03) exigió además un tiempo máximo y un acuse de recibo explícitos.

Caso	Votación	Dónde está el límite
REQ-37	2/3 no ambiguo	La mayoría aceptó “grado de parentesco” como suficientemente claro por el dominio (genealogía animal); la minoría (EXP-03) exigió que el requisito defina cómo se calcula ese grado.
REQ-48	2/3 ambiguo	La mayoría consideró que enumerar los roles sin la matriz de permisos deja el requisito incompleto; la minoría (EXP-02) consideró que definir <i>que</i> debe existir control de acceso por roles ya es suficiente a este nivel de especificación.
REQ-56	2/3 ambiguo	La mayoría consideró que “confirme o cuestione” no define el criterio de resolución ante una discrepancia; la minoría (EXP-02) consideró que ese criterio pertenece al juicio profesional veterinario, no al requisito de software.

Regla derivada: el límite de discrepancia más frecuente en este corpus no es la ausencia de una palabra vaga clásica, sino la pregunta de si un nivel de detalle adicional (umbral, matriz de permisos, criterio de resolución) pertenece al requisito de software o a un artefacto o dominio externo a él.

Registro del entrenamiento previo

El entrenamiento y la evaluación real ocurrieron en una sola sesión, no en dos reuniones separadas: el entrenamiento al inicio, la evaluación real inmediatamente después, en la misma videollamada del 28 de julio de 2026.

Marca de tiempo	Evento
00:00–00:51	Consentimiento de grabación, confirmado individualmente por cada una de las 3 personas expertas.
01:01–02:21	Explicación del objetivo del estudio y del alcance de la evaluación.
02:48–05:12	Entrenamiento: explicación de las 5 categorías de mal olor , cada una con definición operativa y ejemplo (tabla anterior).
06:11–06:45	Confirmación individual, por cada evaluador, de haber recibido la rúbrica de clasificación por correo electrónico.
06:45	Inicio de la evaluación individual e independiente de los 61 requisitos reales (pausa de grabación durante el trabajo autónomo).
30:58	EXP-01 confirma verbalmente haber finalizado y haber enviado su archivo de resultados de inmediato.
34:05	EXP-03 confirma verbalmente haber finalizado; indica que enviará el archivo de inmediato (“ahorita le voy a enviar”).
36:09	EXP-02 confirma verbalmente haber finalizado la evaluación, pero indica que enviará el archivo de resultados <i>esta semana</i> , no de inmediato.

Discrepancia real documentada: la confirmación verbal de haber *finalizado de evaluar* (30:58, 34:05 y 36:09) no equivale, para EXP-02, al momento de *envío* del archivo de resultados él mismo declara que lo enviará “esta semana”, no en el momento de la sesión, a diferencia de EXP-01 y EXP-03. El protocolo verbal de cierre de la sesión no distinguió explícitamente entre ambos momentos para los tres evaluadores por igual.

Evidencia de independencia real: los tres evaluadores confirmaron haber finalizado su evaluación en momentos distintos de la misma sesión (30:58, 34:05, 36:09), consistente con trabajo individual genuino, no coordinado ni copiado entre ellos. La fecha exacta de envío del archivo de EXP-02 posterior a la sesión, según su propia declaración no afecta la independencia del juicio (ya emitido y finalizado antes de conocer cualquier resultado ajeno), pero se documenta aquí para que la trazabilidad temporal sea exacta y no aproximada.

Declaración honesta: no hubo ronda de calibración con resultados medidos

No se realizó una ronda de calibración formal es decir, no se pidió al panel clasificar juntos un subconjunto de casos de prueba antes de la evaluación real, ni se calculó un coeficiente de acuerdo (κ) previo a la recolección para verificar el entendimiento compartido de las categorías antes de aplicarlas al corpus real.

Esta es una limitación real del estudio, declarada aquí de forma explícita en lugar de construir un resultado de calibración que nunca se produjo. Lo que sí existe, con evidencia verificable arriba, es una sesión de entrenamiento y explicación de categorías con ejemplos, seguida de confirmación individual de recepción del instrumento lo cual mitiga parcialmente, aunque no reemplaza, una calibración con acuerdo medido antes de la recolección.

Como evidencia indirecta de que el entendimiento compartido fue, en la práctica, alto: el acuerdo interevaluador calculado *después* de la recolección, sobre los 61 casos reales, fue de κ de Fleiss = 0,857 (“casi perfecto”), reportado en la Sección 7.10.

7.7 Plan de análisis estadístico ejecutado

Análisis principal (RQ1, H0/H1). Se calcularon precisión, exhaustividad y medida F1 del detector automático tomando como referencia el consenso experto. La hipótesis se contrastó mediante chi-cuadrado de independencia de Pearson (véase la desviación documentada en la Sección 7.3), y la magnitud del acuerdo se interpretó con la escala de Landis y Koch [3]: 0,00–0,20 leve; 0,21–0,40 aceptable; 0,41–0,60 moderado; 0,61–0,80 sustancial; 0,81–1,00 casi perfecto.

Acuerdo inter-evaluador. κ de Cohen [4] para cada par de las tres personas expertas, y κ de Fleiss [5] para el conjunto de las tres, interpretados con la misma escala de Landis y Koch.

El análisis secundario exploratorio de RQ2 (comparación del nivel de confianza entre casos de acuerdo y desacuerdo mediante prueba de Shapiro-Wilk seguida de t de Student o U de Mann-Whitney, con corrección de Benjamini-Hochberg para comparaciones por tipo de requisito) no se ejecutó dentro del plazo de la Entrega 4 (2B). RQ2 se respondió de forma cualitativa mediante el análisis de los tipos de mal olor predominantes en los casos de desacuerdo (Sección 7.10), tal como permite el sexto paso del Enfoque 2 en la guía de la asignatura. El análisis cuantitativo de RQ2 queda declarado como trabajo futuro (Sección 7.12).

Cálculo de potencia estadística. Conforme a Molléri et al. [6] y Wohlin et al. [7], se fijó $\alpha = 0,05$ y $1 - \beta = 0,80$. El cálculo de potencia se reportó en sentido inverso sobre el N real disponible (61), mediante remuestreo bootstrap (10 000 réplicas, semilla fija = 42) para el intervalo de confianza al 95 % de cada métrica.

Reproducibilidad. Todos los cálculos se ejecutan mediante los scripts versionados en 06_Experimento/scripts_analisis/ (Python: pandas, scipy, numpy), orquestados por un único punto de entrada (run_all.py). Ninguna cifra o tabla de esta sección se produjo de forma

manual; se verificó la reproducibilidad completa ejecutando el pipeline sobre un clon limpio del repositorio, partiendo únicamente de `datos_crudos/`.

7.8 Registro previo y desviaciones respecto del protocolo

El protocolo del Enfoque 2 se registró en el Open Science Framework [8], mediante la plantilla OSF Preregistration, el 27 de julio de 2026 a las 10:49:41 a.m. (hora de Ecuador), antes de distribuir la rúbrica de clasificación al panel experto y antes de ejecutar el detector automático sobre el corpus de requisitos. El registro puede consultarse en: <https://osf.io/khyf2/overview>.

Comprobante externo. El archivo `06_Experimento/osf_registration.pdf` es una captura directa de la plataforma OSF no un documento redactado por el equipo, que muestra: título del registro (“MundiPets Detección Automática De Ambigüedad En Requisitos”), estado “Aceptado”, fecha de registro (27 de julio de 2026, 10:49:41 a.m.) y colaborador. El registro es anterior a la sesión de entrenamiento y recolección con el panel (28 de julio), tal como exige la práctica de investigación confirmatoria.

Esta sección consolida, en un solo lugar, las tres desviaciones documentadas respecto del protocolo pre-registrado:

1. **Tamaño y composición de la población:** de 30 requisitos previstos (17 RF, 8 RNF, 5 RD) a 61 ejecutados (27 RF, 16 RNF, 9 RD, 9 RL), con la incorporación de la categoría RL no contemplada originalmente (Sección 7.2).
2. **Prueba de significancia estadística:** de la prueba de z sobre el κ de Cohen a chi-cuadrado de independencia de Pearson con corrección de continuidad (Sección 7.3).
3. **Análisis secundario de RQ2:** el componente cuantitativo (Shapiro-Wilk, prueba de comparación de grupos, corrección Benjamini-Hochberg) no se ejecutó; RQ2 se respondió mediante análisis cualitativo de los tipos de mal olor (Sección 7.10).

Ninguna de las tres desviaciones alteró la variable dependiente, el diseño ciego, ni el conjunto de reglas fijas del detector; todas se aplicaron de forma completa sobre el corpus final, no de manera selectiva sobre resultados ya observados.

7.9 Amenazas a la validez

Validez interna

Sesgo de diseño del detector. El equipo que construyó el detector ya conocía, por la revisión manual previa realizada durante el refinamiento del ERS/SRS, algunos de los defectos presentes en una parte del corpus, lo que podría calibrar las reglas hacia esos casos conocidos. *Mitigación:* las reglas del detector se fijaron y documentaron antes de recibir la clasificación completa de los tres expertos, y se aplicaron sin modificación posterior. *Limitación reconocida:* el sesgo no se elimina por completo.

Efecto de orden o fatiga en la evaluación experta. *Mitigación:* orden de presentación aleatorizado de forma independiente para cada evaluador. *Limitación reconocida:* la aleatorización distribuye el efecto pero no lo elimina.

Validez externa

Corpus de un solo sistema y dominio. Los requisitos provienen únicamente de MundiPets, en español, dominio veterinario/adopción de mascotas. *Mitigación:* el contexto queda documentado explícitamente en el marco PICOC. *Limitación reconocida:* no puede afirmarse que el desempeño del detector generalice a otros dominios, idiomas o equipos.

Homogeneidad del panel experto. Las tres personas evaluadoras son ingenieras e ingeniero de software graduados de la misma universidad. *Mitigación:* el perfil del panel se documenta explícitamente. *Limitación reconocida:* no se garantiza representatividad de la diversidad de juicio experto de un panel más amplio o multi-institucional.

Validez de constructo

Binarización de un fenómeno gradual. *Mitigación:* la rúbrica captura matices adicionales mediante el tipo de mal olor y el nivel de confianza. *Limitación reconocida:* la variable principal de análisis sigue siendo binaria.

Alcance limitado de un detector basado en reglas. El detector identifica ambigüedad léxica y sintáctica, no ambigüedad semántica de dominio. *Mitigación:* el alcance de las reglas se documenta explícitamente. *Limitación reconocida:* la comparación mide específicamente cuánta ambigüedad detectable por reglas léxicas coincide con el juicio experto global.

Validez de conclusión

Tamaño de muestra. A diferencia de lo previsto en el registro original que señalaba un N por debajo del mínimo sugerido, el corpus final ejecutado (N=61) supera el mínimo de 50 requisitos sugerido por la guía de la asignatura para este enfoque, lo que mejoró sustancialmente la potencia estadística respecto de lo previsto. *Resultado observado:* con este N, la asociación detector–consenso resultó estadísticamente significativa ($p = 0,0001$), a diferencia de lo que habría ocurrido con el N menor previsto originalmente.

Panel experto mínimo. Solo tres personas conforman el consenso de referencia, el mínimo aceptado por la guía. *Mitigación:* se calculó explícitamente el acuerdo inter-evaluador mediante κ de Fleiss antes de aceptar el consenso como válido (Sección 7.7). *Limitación reconocida:* un panel de tres es más vulnerable a la idiosincrasia individual que un panel de cinco.

7.10 Resultados obtenidos

7.10.1 Clasificación por fuente

Cuadro 5: Clasificación de ambigüedad por fuente (N=61).

Fuente	N	Ambiguos (n)	Ambiguos (%)
EXP-01	61	16	26,23
EXP-02	61	13	21,31
EXP-03	61	18	29,51
Consenso experto	61	16	26,23
Detector automático	61	20	32,79

7.10.2 Acuerdo inter-evaluador

Cuadro 6: Acuerdo inter-evaluador (κ de Cohen por par, κ de Fleiss para el panel).

Comparación	κ	Acuerdo obs.	Interpretación
EXP-01 vs. EXP-02	0,8647	0,9508	Casi perfecto
EXP-01 vs. EXP-03	0,9186	0,9672	Casi perfecto
EXP-02 vs. EXP-03	0,7857	0,9180	Sustancial
Panel completo (κ de Fleiss)	0,8569	0,9454	Casi perfecto

El acuerdo casi perfecto obtenido en el panel completo respalda la validez del consenso experto como referencia para evaluar el detector automático.

7.10.3 Desempeño del detector y prueba de hipótesis

Cuadro 7: Matriz de confusión: detector vs. consenso experto (N=61).

Consenso experto	Detector: No ambiguo	Detector: Ambiguo
No ambiguo	37	8
Ambiguo	4	12

Cuadro 8: Métricas del detector automático con intervalo de confianza al 95 % (bootstrap, 10 000 réplicas).

Métrica	Valor	IC 95 %
Exactitud	0,8033	[0,7049; 0,9016]
Precisión	0,6000	[0,3750; 0,8125]
Sensibilidad	0,7500	[0,5000; 0,9412]
Especificidad	0,8222	[0,7027; 0,9269]
Medida F1	0,6667	[0,4571; 0,8205]
κ detector–consenso	0,5296 (moderado)	[0,2797; 0,7369]

Prueba de hipótesis: $\chi^2(1) = 15,0374$; $p = 0,0001$; $\phi = 0,4965$ (tamaño del efecto moderado grande).

Con $p < 0,05$, se **rechaza H0**: la clasificación del detector automático guarda asociación estadísticamente significativa con el consenso experto, con un tamaño del efecto moderado grande.

7.10.4 Tipos de ambigüedad predominantes (RQ2)

Cuadro 9: Distribución de tipos de mal olor sobre las marcaciones ambiguas.

Tipo de ambigüedad	Frecuencia	%
Terminología imprecisa	18	38,30
Cuantificador vago	15	31,91
Requisito no verificable / incompleto	9	19,15
Conjunción múltiple	5	10,64

El tipo de ambigüedad predominante en los casos marcados por el panel experto es la terminología imprecisa, seguida de cerca por los cuantificadores vagos el tipo de mal olor que el detector basado en reglas está diseñado para capturar de forma más directa, lo que es consistente con la sensibilidad de 0,75 obtenida.

7.11 Síntesis de respuesta a las preguntas de investigación

RQ1. El detector automático basado en reglas replica el juicio consensuado de las personas expertas con una exactitud de 0,8033, una medida F1 de 0,6667 y un acuerdo moderado ($\kappa = 0,5296$) con el consenso experto, una asociación estadísticamente significativa ($\chi^2(1) = 15,0374$; $p = 0,0001$; $\phi = 0,4965$).

RQ2. Los desacuerdos entre el detector y el consenso experto se concentran en requisitos donde predomina la terminología imprecisa y la ausencia de criterio de verificación explícito formas de ambigüedad semántica que requieren juicio de dominio frente a los cuantificadores vagos, que el detector identifica de forma más directa mediante reglas léxicas.

7.12 Trabajo futuro declarado

Como se documenta en la Sección 7.7, el análisis cuantitativo secundario de RQ2 (comparación del nivel de confianza entre casos de acuerdo y desacuerdo, con las pruebas y correcciones originalmente previstas) queda pendiente de ejecución y se declara explícitamente como línea de trabajo futuro sobre el mismo conjunto de datos ya depositado.

Todos los valores numéricos de esta sección provienen directamente de 06_Experimento/resultados/tablas/ (tablas 1 a 9), generadas por los scripts versionados en 06_Experimento/scripts_analisis/ a partir de datos_crudos/. Ningún valor fue calculado, redondeado o transcrito manualmente para este documento.

Referencias

- [1] Ferrari, A., Gnesi, S., & Tolomei, G. (2014). A Case Study on the Impact of Software Requirements Quality on Related Work Products. *Requirements Engineering*, 19(2), 209–234.
- [2] Asamblea Nacional del Ecuador. (2021). *Ley Orgánica de Protección de Datos Personales*. Registro Oficial Suplemento No. 459, 26 de mayo de 2021.
- [3] Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, 33(1), 159–174.
- [4] Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- [5] Fleiss, J. L. (1971). Measuring Nominal Scale Agreement Among Many Raters. *Psychological Bulletin*, 76(5), 378–382.
- [6] Molléri, J. S., Petersen, K., & Mendes, E. (2020). An Empirically Evaluated Checklist for Surveys in Software Engineering. *Information and Software Technology*, 119, 106240.
- [7] Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., & Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.
- [8] Center for Open Science. *Open Science Framework (OSF)*. <https://osf.io>.