

Protocolo Experimental

Componente Empírico del Proyecto MundiPets
Enfoque 2 — Detección Automática de Ambigüedad en Requisitos

Equipo MundiPets
Ingeniería de Requerimientos [20303] — UTEQ 2026-2027 PPA

Quevedo, Ecuador
Julio de 2026

Resumen

Este documento reproduce, de forma independiente y autocontenida, el protocolo del componente empírico del proyecto MundiPets, correspondiente al Enfoque 2 de la guía de la asignatura de Ingeniería de Requerimientos. El protocolo fue registrado de forma previa en el Open Science Framework (OSF) antes de iniciar la recolección de datos, conforme al principio de preregistro [1]. El contenido de este documento corresponde exactamente a la Sección 7 del documento de Especificación de Requisitos de Software (ERS/SRS) de la Entrega 3 (2A) del proyecto.

Índice

7. Componente empírico del proyecto	2
7.1. Enfoque seleccionado y justificación	2
7.2. Preguntas de investigación en formato PICOC	3
7.3. Hipótesis o proposiciones del estudio	3
7.4. Variables independientes, dependientes y de control	3
7.5. Participantes y reclutamiento	4
7.6. Instrumentos	4
7.7. Plan de análisis estadístico	5
7.8. Registro previo del protocolo en el OSF	5
7.9. Amenazas a la validez previstas	6

7 Componente empírico del proyecto

7.1 Enfoque seleccionado y justificación

El equipo optó por el **Enfoque 2 — Detectar automáticamente ambigüedad y malos olores en los requisitos**, descartando el Enfoque 1 (comparación de la calidad de los RF frente a un LLM) y el Enfoque 3 (validación de requisitos de explicabilidad del componente de IA).

Justificación en función del sistema. MundiPets cuenta, desde la Entrega 2 (1B), con un corpus consolidado de especificación (17 RF, 8 RNF y 5 restricciones de diseño), que constituye el insumo directo sobre el cual puede ejecutarse un detector de ambigüedad sin depender de instrumentos adicionales de recolección con usuarios externos al proyecto.

Justificación en función de los datos disponibles. Como parte de la revisión y refinamiento del SRS parcial, el equipo ya efectuó un primer ejercicio de identificación manual de defectos de redacción sobre RF-01 a RF-17 y RNF-01 a RNF-08, detectando patrones de ambigüedad, terminología imprecisa y requisitos no verificables consistentes con los *malos olores* descritos por Ferrari *et al.* [2]. Este antecedente ofrece una base real sobre la cual diseñar y calibrar el detector automático, en lugar de partir desde cero.

Justificación en función del tiempo. Independientemente del tiempo total disponible en el cronograma de la asignatura, el costo temporal de cada enfoque no depende solo de la duración del periodo, sino de la *naturaleza de su ruta crítica*. Los Enfoques 1 y 3 dependen de reclutar y coordinar agendas con personas ajenas al equipo, lo cual introduce una latencia que no se reduce aunque se disponga de más semanas: el Enfoque 1 requiere entre tres y cinco personas evaluadoras externas dispuestas a calificar a ciegas dos conjuntos de al menos 50 RF cada uno, y el Enfoque 3 requiere doce participantes externos distribuidos en dos rondas de validación moderada, con la consiguiente necesidad de encontrar, convocar y agendar a cada uno. En ambos casos, el tiempo de ejecución queda sujeto a la disponibilidad de terceros, un factor fuera del control directo del equipo. El Enfoque 2, en cambio, mantiene su ruta crítica dentro del equipo: solo requiere tres personas expertas ya identificadas y la construcción de un detector automático (un script propio o una herramienta existente), ambas tareas ejecutables sin depender de la disponibilidad de terceros. Por esta razón, el Enfoque 2 ofrece el menor riesgo de cronograma de los tres, con independencia de cuántas semanas se le asignen.

La decisión fue adoptada internamente por el equipo.

7.2 Preguntas de investigación en formato PICOC

Tabla 1: Preguntas de investigación estructuradas según el marco PICOC.

Elemento COC	PI-	Descripción
Población		Conjunto de requisitos funcionales (RF), no funcionales (RNF) y restricciones de diseño (RD) especificados para el sistema MundiPets, redactados según la plantilla de ocho atributos exigida por la asignatura y vigentes al momento de la ejecución del experimento.
Intervención		Clasificación automática de cada requisito como <i>ambiguo</i> o <i>no ambiguo</i> mediante un detector basado en reglas, que identifica cuantificadores vagos, conjunciones múltiples que ocultan más de un requisito, voz pasiva y ausencia de criterio de verificación explícito.
Comparación		Clasificación manual e independiente del mismo conjunto de requisitos, realizada por tres personas expertas en Ingeniería de Requisitos, sin conocimiento previo de la salida del detector (evaluación a ciegas).
Resultado		Precisión, exhaustividad (<i>recall</i>) y medida F1 del detector automático tomando como referencia el consenso experto; acuerdo inter-evaluador mediante κ de Cohen entre pares de expertos y κ de Fleiss para el conjunto de los tres.
Contexto		Proyecto académico de la asignatura de Ingeniería de Requerimientos [20303] (UTEQ, 2026-2027 PPA), aplicado al sistema real MundiPets, con especificación redactada en español.
RQ1		¿Con qué precisión, exhaustividad y medida F1 replica un detector automático basado en reglas el juicio consensuado de personas expertas al clasificar como ambiguos los requisitos especificados para MundiPets?
RQ2		¿Qué patrones de desacuerdo predominan entre el detector automático y el juicio experto, y qué explican sobre las limitaciones de un enfoque basado en reglas frente al juicio humano en la identificación de ambigüedad?

7.3 Hipótesis o proposiciones del estudio

Al tratarse del Enfoque 2, el diseño corresponde a un cuasi-experimento y requiere hipótesis nula y alternativa, no proposiciones de estudio de caso.

H₀ (hipótesis nula): la clasificación producida por el detector automático de ambigüedad no guarda asociación con la clasificación de consenso de las personas expertas; el acuerdo observado entre ambas (κ de Cohen) no es significativamente distinto del acuerdo esperado por azar ($\kappa = 0$).

H₁ (hipótesis alternativa): la clasificación producida por el detector automático de ambigüedad guarda asociación significativa con la clasificación de consenso de las personas expertas; el acuerdo observado entre ambas es significativamente mayor que el esperado por azar ($\kappa > 0$).

Esta hipótesis se contrasta mediante la prueba de significancia del κ de Cohen descrita en la Sección 7.7. La pregunta RQ2, al ser de carácter exploratorio sobre los patrones de desacuerdo, no se somete a prueba de hipótesis: se responde mediante análisis cualitativo de los casos en los que el detector y el consenso experto difieren, siguiendo el sexto paso descrito para el Enfoque 2 en la guía de la asignatura.

7.4 Variables independientes, dependientes y de control

Variable independiente. El método de clasificación aplicado a cada requisito, con dos niveles: (a) detector automático basado en reglas y (b) consenso de las tres personas expertas.

Variable dependiente. La clasificación resultante de cada requisito como *ambiguo* o *no ambiguo*

(variable categórica binaria), a partir de la cual se calculan las métricas de acuerdo declaradas en la Sección 7.7 (precisión, exhaustividad, medida F1 y κ).

Variables de control.

- **Tipo de requisito** (RF, RNF o RD), para verificar que el desempeño del detector no varíe sistemáticamente según el tipo de artefacto evaluado.
- **Configuración fija del detector**: el conjunto de reglas (cuantificadores vagos, conjunciones múltiples, voz pasiva, ausencia de criterio de verificación) permanece invariable durante toda la ejecución del experimento; ninguna regla se ajusta después de observar resultados parciales.
- **Orden de presentación** de los requisitos a las personas expertas, aleatorizado de forma independiente para cada evaluador, con el fin de controlar efectos de fatiga o de orden.
- **Cegamiento del juicio experto**: ninguna persona evaluadora tiene acceso a la salida del detector ni a la clasificación de las demás personas evaluadoras antes de completar la propia.

7.5 Participantes y reclutamiento

El estudio involucra dos grupos con roles distintos: las personas expertas que ejecutan la clasificación de referencia, y el equipo de MundiPets, que construye y aplica el detector automático sin participar en la clasificación experta, para preservar la independencia del juicio.

Personas expertas. El panel está compuesto por tres Ingenieros de Software graduados de la Universidad Técnica Estatal de Quevedo (UTEQ) (dos mujeres y un hombre), ya contactados y confirmados para participar en el estudio.

Criterios de inclusión: (a) título profesional de tercer nivel en Ingeniería de Software o carrera afín; (b) formación o experiencia demostrable en especificación y análisis de requisitos de software; (c) disponibilidad para completar la clasificación dentro del cronograma del estudio.

Criterios de exclusión: (a) pertenecer al equipo de desarrollo de MundiPets; (b) haber participado en la redacción de los RF, RNF o RD que conforman la población del estudio (Sección 7.2).

Proceso de consentimiento informado. Cada persona evaluadora firmó, el 28 de julio de 2026, un consentimiento informado específico para este rol, redactado en cumplimiento de la Ley Orgánica de Protección de Datos Personales del Ecuador [3], que autoriza expresamente su participación como evaluadora experta y el uso de la clasificación producida –de forma anonimizada– en publicaciones científicas revisadas por pares. La plantilla se detalla en la Sección 7.6.

7.6 Instrumentos

Los instrumentos del Enfoque 2 son dos:

1. **Rúbrica de clasificación experta** (`rubrica_clasificacion_experta.xlsx`): libro con hoja de instrucciones, hoja de criterios de referencia para identificar ambigüedad, y hoja de evaluación en la que cada persona evaluadora registra, para cada requisito, su identificador, el texto completo, la clasificación (*ambiguo* / *no ambiguo*), el tipo de mal olor detectado y una justificación breve. Los requisitos se presentan sin indicar su tipo (RF, RNF o RD) y en orden aleatorizado, para reducir sesgos de expectativa. Una hoja adicional, de uso exclusivo del equipo, conserva la clave que vincula cada identificador anónimo con el requisito real y la salida del detector.
2. **Plantilla de consentimiento para evaluadores expertos** (`consentimiento_evaluador_experto.docx`): adapta el formato de consentimiento ya utilizado en la Entrega 1B para entrevistas, ajustado al rol de evaluador experto e incorporando la autorización explícita para el uso de datos anonimizados en publicaciones revisadas por pares, conforme a la LOPDP [3].

7.7 Plan de análisis estadístico

La variable central de este estudio (clasificación *ambiguo/no ambiguo*) es categórica, por lo que el análisis principal no se basa en comparación de medias sino en métricas de acuerdo. A continuación se detalla cómo se instancia cada elemento mínimo exigido por la guía.

Análisis principal (RQ1, H_0/H_1). Se calculan precisión, exhaustividad y medida F1 del detector automático tomando como referencia el consenso experto (Sección 7.3). La hipótesis se contrasta mediante una prueba de significancia del κ de Cohen (estadístico $z = \kappa/SE_\kappa$, contra la distribución normal estándar), mientras que la magnitud del acuerdo se interpreta como el tamaño del efecto, usando la escala de Landis y Koch: 0,00–0,20 leve; 0,21–0,40 aceptable; 0,41–0,60 moderado; 0,61–0,80 sustancial; 0,81–1,00 casi perfecto.

Acuerdo inter-evaluador. κ de Cohen [4] para cada par de las tres personas expertas, y κ de Fleiss [5] para el conjunto de las tres, interpretados con la misma escala de Landis y Koch. Un acuerdo experto bajo relativizaría cualquier conclusión sobre el desempeño del detector, ya que el propio consenso de referencia quedaría en duda.

Prueba de normalidad (Shapiro-Wilk). Se aplica sobre la variable continua *nivel de confianza* (escala 1–5) registrada en la rúbrica de evaluación (Sección 7.6), como paso previo al análisis exploratorio secundario descrito a continuación.

Análisis secundario (RQ2, exploratorio). Para caracterizar los casos de desacuerdo entre el detector y el consenso experto, se compara el nivel de confianza reportado por las personas expertas entre los requisitos donde el detector coincide con el consenso y aquellos donde difiere. Si Shapiro-Wilk no rechaza normalidad, se usa la prueba t de Student para muestras independientes y el tamaño del efecto se reporta como d de Cohen; en caso contrario, se usa la prueba U de Mann-Whitney y el tamaño del efecto como δ de Cliff. Este análisis es exploratorio y se complementa con la nota cualitativa de desacuerdos exigida por el sexto paso del Enfoque 2 en la guía de la asignatura.

Corrección por comparaciones múltiples. Si además se reportan métricas de acuerdo desagregadas por tipo de requisito (RF, RNF, RD) como análisis exploratorio adicional, los valores p resultantes de esas tres comparaciones relacionadas se ajustan mediante el procedimiento de Benjamini-Hochberg (control de la tasa de falsos descubrimientos).

Cálculo de potencia estadística. Conforme a Molléri *et al.* [6] y Wohlin *et al.* [7], se fija $\alpha = 0,05$ y $1 - \beta = 0,80$. Dado que el tamaño de la población está acotado por el corpus real de especificación disponible (Sección 7.1) y no por una meta de reclutamiento ampliable, el cálculo de potencia se reporta en sentido inverso: en lugar de fijar un N objetivo, se determina la sensibilidad mínima (el valor mínimo de κ detectable) que el diseño puede identificar con ese α y esa potencia, dado el N realmente disponible al momento de la ejecución. Este cálculo se documentará con el valor real de N y se versionará junto con el resto del análisis.

Reproducibilidad. Todos los cálculos anteriores se ejecutan mediante scripts versionados en 06_Experimento/scripts_analisis/ (Python, con SciPy/statsmodels o R); ninguna cifra o tabla de esta sección se produce de forma manual, conforme a la regla de la guía de la asignatura.

7.8 Registro previo del protocolo en el OSF

El protocolo del Enfoque 2 se registró en el Open Science Framework [1], mediante la plantilla *OSF Preregistration*, el **27 de julio de 2026 a las 10:49:41 a.m.** (hora de Ecuador), antes de distribuir la rúbrica de clasificación al panel experto y antes de ejecutar el detector automático sobre el corpus de requisitos. El registro ya fue **aprobado** por OSF y puede consultarse directamente, sin necesidad de iniciar sesión, en: <https://osf.io/khyf2/overview>.

Alcance de la plataforma OSF en este diseño. El Open Science Framework es una aplica-

ción de gestión de proyectos e infraestructura abierta de investigación –registro previo, control de versiones, colaboración y asignación de identificadores persistentes (DOI)–, no una herramienta de recolección de datos primarios: no ofrece un constructor de formularios o encuestas equivalente a instrumentos como Google Forms o Qualtrics [1]. Por esta razón, la clasificación experta (Sección 7.6) se recolecta fuera de OSF, mediante la rúbrica en formato de hoja de cálculo distribuida directamente a las personas evaluadoras, y los archivos resultantes –junto con los scripts de análisis y los resultados– se depositan posteriormente en el mismo proyecto de OSF ya registrado, para centralizar el material de replicación conforme a los principios FAIR [8].

7.9 Amenazas a la validez previstas

Validez interna.

- *Sesgo de diseño del detector.* El equipo que construye el detector ya conoce, por la revisión manual previa realizada durante el refinamiento del SRS parcial (Sección 7.1), algunos de los defectos presentes en RF-01 a RF-17, lo que podría calibrar las reglas hacia esos casos conocidos e inflar artificialmente la precisión. **Mitigación:** las reglas del detector (Sección 7.1) se fijan y documentan antes de recibir la clasificación de los tres expertos sobre el conjunto completo, y se aplican sin modificación posterior (Sección 7.4). **Limitación reconocida:** el sesgo no se elimina por completo, porque el conocimiento previo del equipo sobre una parte del corpus es inevitable; se atenúa parcialmente al incluir en la población los RF-18 a RF-25, que no formaron parte de esa revisión previa.
- *Efecto de orden o fatiga en la evaluación experta.* Evaluar un conjunto largo de requisitos de forma consecutiva puede degradar el juicio hacia el final del ejercicio. **Mitigación:** orden de presentación aleatorizado de forma independiente para cada evaluador (Sección 7.4). **Limitación reconocida:** la aleatorización distribuye el efecto pero no lo elimina; no se mide directamente si la fatiga afectó casos específicos.

Validez externa.

- *Corpus de un solo sistema y dominio.* Los requisitos provienen únicamente de MundiPets, redactados en español por un solo equipo estudiantil en el dominio veterinario/adopción de mascotas. **Mitigación:** el contexto queda documentado explícitamente en el marco PICOC (Sección 7.2) para que cualquier lector pueda evaluar la transferibilidad. **Limitación reconocida:** no puede afirmarse que el desempeño del detector generalice a otros dominios, idiomas o equipos con distinto nivel de experiencia; el estudio se declara como un caso único, no como una validación general del detector.
- *Homogeneidad del panel experto.* Las tres personas evaluadoras son Ingenieras e Ingeniero de Software graduados de la misma universidad (UTEQ). **Mitigación:** el perfil exacto del panel se documenta en la Sección 7.5. **Limitación reconocida:** no se garantiza representatividad de la diversidad de juicio experto que existiría con un panel de otras instituciones o con mayor trayectoria profesional.

Validez de constructo.

- *Binarización de un fenómeno gradual.* La ambigüedad rara vez es todo-o-nada; reducirla a *ambiguo/no ambiguo* simplifica un constructo más complejo. **Mitigación:** la rúbrica captura matices adicionales mediante el campo *tipo de mal olor detectado* y el *nivel de confianza* (Sección 7.6). **Limitación reconocida:** la variable principal de análisis sigue siendo binaria; se acepta esta simplificación como necesaria para el análisis cuantitativo dentro del tiempo disponible.
- *Alcance limitado de un detector basado en reglas.* El detector identifica ambigüedad léxica y sintáctica (cuantificadores vagos, voz pasiva, conjunciones múltiples), pero no ambigüedad semántica de dominio que solo una persona con conocimiento veterinario puede reconocer.

Mitigación: el alcance de las reglas se documenta explícitamente y no se presenta el detector como un sustituto general del juicio experto. **Limitación reconocida:** la comparación mide específicamente cuánta ambigüedad *detectable por reglas léxicas* coincide con el juicio experto global, no toda forma posible de ambigüedad.

Validez de conclusión.

- *Tamaño de muestra reducido.* La población disponible (Sección 7.1) es menor al mínimo de 50 requisitos sugerido por la guía de la asignatura para este enfoque, lo que reduce la potencia para detectar valores pequeños de κ como significativamente distintos de cero. **Mitigación:** el plan de análisis (Sección 7.7) reporta explícitamente la sensibilidad mínima detectable dado el N real, en vez de ocultar la limitación. **Limitación reconocida:** con un N reducido, el estudio puede no tener potencia suficiente para detectar niveles de acuerdo moderados-bajos como estadísticamente significativos; los resultados de la Entrega 4 deberán interpretarse con este límite en mente.
- *Panel experto mínimo.* Solo tres personas conforman el consenso de referencia, el mínimo aceptado por la guía; con un panel tan pequeño, la opinión de una sola persona pesa proporcionalmente más sobre el consenso. **Mitigación:** se calcula explícitamente el acuerdo inter-evaluador mediante κ de Fleiss antes de aceptar el consenso como válido. **Limitación reconocida:** un panel de tres es más vulnerable a la idiosincrasia individual que el panel de cinco recomendado por la guía, al que no se llega por restricciones de tiempo.

Referencias

- [1] B. A. Nosek, C. R. Ebersole, A. C. DeHaven y D. T. Mellor, “The Preregistration Revolution,” *Proceedings of the National Academy of Sciences*, vol. 115, n.º 11, págs. 2600-2606, 2018. DOI: 10.1073/pnas.1708274114.
- [2] A. Ferrari, P. Spoletini y S. Gnesi, “Ambiguity and Tacit Knowledge in Requirements Elicitation Interviews,” *Requirements Engineering*, vol. 21, n.º 3, págs. 333-355, 2016. DOI: 10.1007/s00766-016-0249-3.
- [3] Asamblea Nacional del Ecuador, “Ley Orgánica de Protección de Datos Personales,” Asamblea Nacional del Ecuador, Quito, Ecuador, Registro Oficial Suplemento No. 459, 2021.
- [4] J. Cohen, “A Coefficient of Agreement for Nominal Scales,” *Educational and Psychological Measurement*, vol. 20, n.º 1, págs. 37-46, 1960. DOI: 10.1177/001316446002000104.
- [5] J. L. Fleiss, “Measuring Nominal Scale Agreement Among Many Raters,” *Psychological Bulletin*, vol. 76, n.º 5, págs. 378-382, 1971. DOI: 10.1037/h0031619.
- [6] J. S. Molléri, K. Petersen y E. Mendes, “An Empirically Evaluated Checklist for Surveys in Software Engineering,” *Information and Software Technology*, vol. 119, pág. 106 240, 2020. DOI: 10.1016/j.infsof.2019.106240.
- [7] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell y A. Wesslén, *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012, ISBN: 978-3-642-29043-5. DOI: 10.1007/978-3-642-29044-2.
- [8] M. D. Wilkinson et al., “The FAIR Guiding Principles for Scientific Data Management and Stewardship,” *Scientific Data*, vol. 3, n.º 160018, págs. 1-9, 2016. DOI: 10.1038/sdata.2016.18.